

Aplicação de Redes Convolucionais Profundas para Detecção de Massas em Mamografias

R.A.P. Martins¹ e D. Silva¹

¹ Departamento de Engenharia Elétrica e Eletrônica, Universidade Federal de Santa Catarina, Florianópolis, Brasil

Resumo— Câncer de mama é um dos tipos de câncer mais comuns entre mulheres no mundo. A alta taxa de incidência e mortalidade da doença exige o desenvolvimento de técnicas que permitam agilizar o diagnóstico médico. Este trabalho propõe um algoritmo de processamento de imagens baseado em redes convolucionais profundas para detecção de massas em exames de mamografia, que é o tipo de exame de imagem mais abrangente para avaliação médica do câncer de mama. O objetivo é possibilitar a criação de uma ferramenta de auxílio ao diagnóstico médico, permitindo que o profissional da saúde realize um diagnóstico ainda mais preciso e precoce. Com o uso de um detector convolucional de um estágio (RetinaNet), o algoritmo desenvolvido obtém uma sensibilidade de 85% com uma média de 1,64 falsos positivos por imagem no banco de dados CBIS-DDSM (*Curated Breast Imaging Subset of DDSM*).

Palavras-chave— Câncer de mama. Redes neurais convolucionais profundas. Diagnóstico assistido por computador. Detecção de objetos.

Abstract— Breast cancer is one of the most common types of cancer among women in the world. The high incidence and mortality rate of the disease requires the development of techniques that allow for a faster medical diagnosis. This work proposes an image processing algorithm based on deep convolutional networks for the detection of masses in mammography exams, which is the most comprehensive type of image exam for medical evaluation of breast cancer. The goal is to enable the creation of a tool to aid medical diagnosis, allowing the health professional to make an even more accurate and early diagnosis. Using a one-stage convolutional detector (RetinaNet), the developed algorithm achieves a sensitivity of 85% with an average of 1.64 false positives per image in the CBIS-DDSM database (*Curated Breast Imaging Subset of DDSM*).

Keywords— Breast cancer. Deep convolutional neural networks. Computer-aided diagnosis. Object detection.

I. INTRODUÇÃO

O câncer de mama é uma doença causada por mutações genéticas que levam ao crescimento anormal e desordenado

de células do tecido mamário. Apesar de acometer homens e mulheres, é 100 vezes mais comum em pacientes femininos, sendo a forma de câncer mais frequente neste público [1]. No Brasil, o câncer de mama representa 29% dos novos diagnósticos oncológicos registrados em mulheres anualmente, com estimados 59.700 novos casos para 2019 [2]. Em 2015 a taxa de mortalidade pós-diagnóstico no Brasil foi estimada em 13,68 óbitos/100 mil mulheres [2]. É unânime entre profissionais da saúde que é vital para o prognóstico positivo do câncer de mama que haja o diagnóstico precoce e preciso [3], com redução drástica de óbitos para pacientes com hábitos de vida saudáveis e que realizam exames anuais [2].

Redes convolucionais tem sido fortemente utilizadas para solucionar tarefas de visão computacional como classificação de imagens, detecção de objetos e segmentação semântica [4]. Nos últimos anos, o estado da arte nessas aplicações tem sido marcado pelo uso de redes convolucionais, como AlexNet [5], VGGNet [6] e ResNet [7], aumentando significativamente o nível de sensibilidade máximo alcançado pelos algoritmos. O uso de redes convolucionais tem avançado também o desenvolvimento de ferramentas de auxílio ao diagnóstico médico (CAD). Essas ferramentas têm mostrado resultados promissores em diversas áreas, como Alzheimer [8, 9], doenças pulmonares [10, 11] e em mamografias [12].

Este artigo apresenta um algoritmo para detecção de massas em imagens de mamografias, com objetivo de auxiliar o diagnóstico médico. Nosso algoritmo é inspirado no trabalho de Jung et al. [13], sobretudo no uso da estrutura RetinaNet na detecção de objetos, no entanto, difere-se deste nos seguintes aspectos:

- Utilizamos etapas de pré- e pós-processamento com divisão da imagem em regiões de tamanho fixo, permitindo o treinamento com imagens de alta resolução em *hardware* com memória limitada;
- O treinamento e avaliação do modelo são realizados com o conjunto de dados público CBIS-DDSM [14].

Os resultados obtidos se mostram comparáveis aos de outros trabalhos que utilizam o mesmo conjunto de dados.

II. TRABALHOS RELACIONADOS

O uso de técnicas de aprendizado de máquina para análise de imagens médicas tem crescido rapidamente nos últimos anos. Aplicações em diversas modalidades de imagens são pesquisadas constantemente, obtendo resultados promissores e facilitando o trabalho médico.

O desenvolvimento de ferramentas de auxílio ao diagnóstico de imagens de mamografia é um trabalho que começou já na década de 1990 [12]. Existem diversos trabalhos que utilizam diferentes técnicas aplicadas a classificação e detecção de anomalias, porém o resultado apresentado pelas técnicas tradicionais de visão computacional, como filtros e descritores, não se mostra suficiente para a melhoria do diagnóstico médico final [15, 16]. Atualmente há muito interesse na aplicação de redes neurais na construção de ferramentas de auxílio ao diagnóstico [8, 10, 11]. Com o crescente desenvolvimento na área de redes neurais, e em particular de redes convolucionais, surge uma nova técnica que pode ser utilizada para aprimorar os resultados obtidos.

As estruturas convolucionais modernas (como ResNet [7]) e detectores (Faster-RCNN [17], RetinaNet [18]) se mostram superiores às técnicas tradicionais em diversas áreas de aplicação, e portanto busca-se aplicar estas mesmas técnicas na análise de imagens médicas.

Os trabalhos de [19], [20] utilizam métodos como filtragem, descritores e métodos baseados em regras (*Rule Based Methods*) para detecção de massas em exames de mamografia. Em [21] é realizada a detecção de massas pelo uso misto de descritores e redes neurais, onde uma rede neural é utilizada para implementar o papel de classificador, analisando o resultado obtido a partir do uso de descritores na imagem original.

O trabalho de Shen et al. [22] realiza a detecção de massas e calcificações utilizando uma rede puramente convolucional (treinamento “*end-to-end*”). A estrutura desenvolvida aplica o classificador de uma maneira similar a um filtro de janela móvel (*sliding window*) por toda a imagem, produzindo um mapa de calor de classificações. A maior contribuição deste trabalho é o desenvolvimento de um método eficiente para o treinamento da rede. A inferência continua sendo feita na imagem completa, enquanto o treinamento é realizado separadamente, por partes. A rede final pode ser adaptada para um classificador global, que produz uma predição única para a imagem (existência ou não de uma anomalia). Isso permite que a rede seja aperfeiçoada (*fine tuned*) para um novo banco de dados, com um treinamento semi-supervisionado (amostras que contém apenas classificação global).

Jung et al. [13] realizam a detecção de massas em exames de mamografia utilizando um detector de um estágio pura-

mente convolucional (RetinaNet [18]). Os resultados mostrados no trabalho são comparáveis ou superiores aos encontrados em outros trabalhos do estado da arte, alcançando alta precisão e sensibilidade nas detecções. O treinamento e avaliação desta rede é feita com os bancos de dados GURO e INbreast [23]. GURO é um conjunto criado internamente pelos desenvolvedores e não é disponibilizado publicamente, enquanto INbreast [23] é acessível via requisição, porém dispõe de uma licença de uso limitada.

O presente artigo baseia-se na abordagem de [13] para o desenvolvimento do detector de massas, porém os algoritmos de pré-processamento e pós-processamento foram modificados a fim de simplificar a arquitetura, viabilizando sua execução em tempo real. Outra diferença importante é que a avaliação dos resultados e a comparação com outros trabalhos são feitas utilizando o conjunto de dados público CBIS-DDSM [14].

III. FUNDAMENTAÇÃO TEÓRICA

A. Redes Neurais Convolucionais

Redes neurais convolucionais são modelos computacionais extremamente eficazes para a realização de tarefas como classificação e detecção de objetos em imagens [24]. Essas estruturas, compostas por diversos filtros convolucionais (filtros digitais bidimensionais que realizam a função de convolução sobre a imagem de entrada) dispostos em camadas, permitem desenvolver algoritmos extremamente complexos que ultrapassam a capacidade de algoritmos convencionais da área de visão computacional [6].

As redes convolucionais são fundamentalmente compostas por filtros convolucionais, cujos parâmetros são otimizados iterativamente com o uso de *backpropagation* [24] e de um conjunto de dados suficiente para a otimização dos parâmetros da rede. Arquiteturas convolucionais diferem entre si pela forma em que os filtros convolucionais são dispostos em sua estrutura. Uma parte essencial da pesquisa na área de aprendizado de máquina está na busca de arquiteturas mais eficientes e apropriadas para diferentes problemas.

B. RetinaNet

RetinaNet é uma rede neural puramente convolucional, que realiza a tarefa de detecção de objetos em uma arquitetura de um estágio. O objetivo dessa estrutura é alcançar um alto grau de acurácia sem a necessidade de utilizar uma etapa intermediária para seleção de regiões candidatas na imagem, em contraste a outros detectores como *R-CNN* [25] e *Faster R-CNN* [17].

Essa arquitetura utiliza diversos componentes para resolver diferentes problemas enfrentados por detectores convolucionais. Entre eles está o uso de Redes Residuais (ResNet) [7] no *backbone*, escolhido por ter um esquema convolucional com facilidade de treinamento; o uso de *Feature Pyramid Networks* (FPN) [26] para avaliação multi-escala da imagem; e Perda Focal (*Focal Loss*) [18] como função de perda para a otimização da rede.

A Fig. 1 mostra de forma geral a rede RetinaNet e seus principais componentes.




Fig. 1: Estrutura geral da rede RetinaNet. Consiste de **a)** um *backbone* convolucional primário, **b)** uma construção *Pyramid Feature Network* para análise multi-escala, **c)** uma sub-rede para a classificação e **d)** uma para refinamento de cada detecção

C. Perda Focal

A arquitetura RetinaNet utiliza como função de perda a chamada Perda Focal, a qual é considerada um componente essencial para o treinamento de um detector de um estágio.

Como esta arquitetura não contém um estágio intermediário para avaliação de regiões de interesse, cada detecção consiste na classificação de todas as regiões da imagem. Desta forma, é necessário uma função de perda que permita trabalhar com uma proporção extremamente baixa de detecções para *background*.

A Perda Focal é uma variação da perda por Entropia Cruzada (EC) que diminui a relevância das detecções que já estão corretas na otimização da rede. Essa função é essencial para o treinamento de redes RetinaNet, pois ela prioriza a classificação das poucas regiões com objetos, enquanto diminui a relevância das regiões de *background*. A Perda Focal é descrita matematicamente por

$$FL(p, y) = -\alpha_y (1 - p_y)^\gamma \log(p_y)$$

$$p_y = \begin{cases} p, & \text{se } y = 1 \\ 1 - p, & \text{se } y = 0 \end{cases} \quad (1)$$

$$\alpha_y = \begin{cases} \alpha, & \text{se } y = 1 \\ 1 - \alpha, & \text{se } y = 0 \end{cases}$$

onde p é a predição da rede e $y \in \{0, 1\}$ é o valor verdadeiro de uma classificação. O fator de foco $\gamma \geq 0$ determina o

comportamento do treinamento em relação a amostras já bem classificadas. Com $\gamma > 0$, dá-se mais importância para amostras incorretamente classificadas. Com $\gamma = 0$ a função se reduz a Entropia Cruzada. Já o fator de ponderação $\alpha \in [0, 1]$ é utilizado para contornar o desbalanceamento entre classes.

IV. METODOLOGIA

A. Conjunto de dados

O conjunto de dados utilizado é o CBIS-DDSM (*Curated Breast Imaging Subset of Digital Database for Screening Mammography*) [14]. Este banco de dados dispõe de uma versão revisada dos dados disponíveis originalmente pelo projeto DDSM [27], contendo imagens anotadas de exames de mamografia. No total, o banco de dados contém 1488 imagens com massas encontradas, totalizando 2015 anomalias. O conjunto de dados é separado em três grupos, para treinamento, validação e teste (com 1138, 95 e 255 imagens, respectivamente). Devido ao reduzido número de imagens, escolheu-se dar prioridade ao conjunto de teste e reduzir o conjunto de validação, já que a estrutura RetinaNet não necessitou de ajustes nos hiperparâmetros, e 95 exemplos se mostraram suficientes para ajustar os procedimentos de pré- e pós-processamento.

B. Pré-processamento

Um dos desafios desse projeto é a complexidade computacional necessária para avaliar as imagens. A resolução das imagens, tipicamente em torno de 4000×3000 pixels, é maior do que a usada na maioria das aplicações de visão computacional, gerando um problema grave em questão de consumo memória e tempo de processamento.

A região de interesse (ROI) das imagens tem tamanho variável, mas pode chegar a espaços de 100×100 pixels. Dessa forma, o downsampling realizado é limitado em um fator de 50%, que reduz a complexidade, mas empiricamente não demonstra queda no desempenho da rede. Apesar da diminuição da resolução, ainda não é prático avaliar a imagem por inteiro com a rede convolucional utilizada. A solução adotada é a subdivisão da imagem em regiões de tamanho fixo, que são avaliadas independentemente. Estas regiões tem tamanho de 512×512 pixels e são extraídas da imagem original com uma sobreposição de 256 pixels em cada dimensão.

C. Configuração RetinaNet

A estrutura convolucional utilizada para realizar a detecção foi a rede RetinaNet. A implementação e os hiperparâme-

tros utilizados seguem as indicações do artigo original, com certas adaptações feitas de acordo com o presente problema:

- *Backbone network*: foi utilizada uma rede residual para realizar o papel de backbone do detector. Foi escolhida especificamente a rede ResNet-50 [7], com fim de balancear o desempenho e complexidade computacional.
- *Transfer-learning*: foi utilizada a técnica de transferência de aprendizado, onde os parâmetros internos do *backbone* utilizado foram pré-treinados no banco de dados ImageNet.
- Resolução: a resolução de entrada da rede foi definida em 512×512 pixels.
- Fator de Foco e Ponderação: a função de perda é parametrizada com $\gamma = 2$ e $\alpha = 0.25$.

A arquitetura foi treinada por 24 épocas de 10.000 passos (com repetição aleatória das imagens), otimizador SGD, taxa de aprendizado inicial de 10^{-3} , decaimento *time inverse decay* com fator de 10^{-5} e momento 0.9.

D. Pós-processamento

As saídas da rede RetinaNet consistem na localização e classificação de diversas regiões retangulares da imagem, em diferentes escalas e proporções. Cada subdivisão de 512×512 pixels da imagem original recebe até 300 detecções. Dessa forma, é necessário filtrar os resultados obtidos, para um número menor de detecções por imagem. Isso é feito utilizando um algoritmo de agrupamento, dado por

$$P'_i = \sum_{j=1}^K IoU(A_i, A_j) P_j \quad (2)$$

onde P_n corresponde à pontuação original e P'_n à nova pontuação da detecção A_n , K é o número total de predições, e

$$IoU(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (3)$$

denominada IoU (*Intersection over Union*), é uma métrica de similaridade entre as detecções, a qual contabiliza a razão entre os números de pixels da intersecção e da união de duas regiões.

Em seguida, é aplicado o algoritmo NMS (*Non-Maximum Supression*) [28], que promove cada grupo de detecções para apenas os representantes com maiores pontuações. Esse método leva em consideração a probabilidade prevista e o valor de IoU entre cada par de predições. Por fim, seleciona-se no máximo 5 detecções, escolhendo aquelas acima de um limiar de pontuação.

Tabela 1: Comparação do desempenho de diferentes métodos. Todas as avaliações são referentes a imagens do banco de dados DDSM [14] ou variações deste com objetivos específicos (tipos de massas detectadas) mostrados na tabela. Métrica utilizada TPR@FPPI (taxa de verdadeiro positivo para um dado valor médio de falsos positivos por imagem)

	TPR@FPPI	Tipos de massas
Este trabalho	0.85 @ 1.64 0.81 @ 1.25	Todos
Sampat et al. [20]	0.88 @ 2.7 0.85 @ 1.5 0.80 @ 1.0	Massas espiculadas
Eltonsy et al. [19]	0.92 @ 5.4 0.88 @ 2.4 0.81 @ 0.6	Massas malignas
Eltonsy et al. [19]	0.61 @ 5.1 0.58 @ 2.8	Massas benignas
Beller et al. [29]	0.70 @ 8.0	Massas espiculadas
Campanini et al. [30]	0.80 @ 1.1	Todos
Dhungel et al. [31]	0.75 @ 4.8 0.70 @ 4.0	Todos

V. RESULTADOS

O modelo foi treinado e avaliado com uma GPU NVIDIA GeForce GTX 1050 4GB e 16GB de memória RAM, de forma que o tempo de inferência alcançado é de menos de 10 segundos por imagem.

As predições são avaliadas de acordo com o valor de IoU observado, dado por (3). Uma detecção é considerada correta (verdadeiro positivo) se o valor de IoU em relação à uma anomalia é maior que um determinado limiar, caso contrário a detecção é considerada incorreta (falso positivo). No caso de múltiplas detecções coincidindo com uma mesma anomalia, apenas uma delas é considerada correta, e as outras incorretas. O limiar escolhido é $IoU > 0.2$, valor normalmente utilizado em outros modelos de detecção de massas [13].

A métrica de avaliação dos resultados utilizada é a taxa de verdadeiro positivo (TPR) dado um nível médio de falsos positivos por imagem (FPPI). Essa é a principal métrica utilizada nos trabalhos relacionados, porque leva em consideração tanto a capacidade do algoritmo de identificar corretamente as imagens que contém massas quanto de minimizar o número de falsos positivos.

A Tabela 1 compara os resultados obtidos com outras publicações no mesmo conjunto de dados. Este trabalho obtém uma sensibilidade máxima de 85% com uma média de 1,64 falsos positivos por imagem. Observa-se que, apesar deste trabalho avaliar todos os tipos de massas em imagens de mamografia, tanto a sensibilidade quanto a média de falsos positivos por imagem é superior ou compatível com os outros




Fig. 2: Desempenho das predições para diferentes valores de limiares de detecção. O gráfico apresenta os pontos de TPR (taxa de verdadeiro positivo) em função do número de falsos positivos por imagem. Diferentes curvas são apresentadas, para subconjuntos de imagens com densidades específicas e para o conjunto total de imagens. Observa-se que o desempenho das predições cai de acordo com o aumento da densidade do tecido presente nas imagens

trabalhos comparados.

A curva FROC (*Free-Response Receiver Operating Characteristic*), na Fig. 2, traça o desempenho da rede para diferentes limiares de avaliação, com os valores de taxa de verdadeiro positivo e número de falsos positivos por imagem para cada ponto da curva. A Fig. 3 mostra dois exemplos de detecção com as correspondentes pontuações de cada achado.

VI. CONCLUSÃO

De acordo com a literatura atual, sabe-se que as redes convolucionais são o estado da arte na área de detecção de objetos. Estudos mostram sucesso na aplicação de redes convolucionais na análise de diversos tipos de imagens médicas [8, 10, 11], inclusive em exames de mamografia [12].

Por esse motivo, utilizou-se redes convolucionais profundas para o desenvolvimento de um algoritmo para auxiliar o diagnóstico de câncer de mama. Alta sensibilidade, poucos falsos positivos e baixo tempo de execução foram buscados utilizando redes de detecção de um estágio, que se mostram bem-sucedidas para este tipo de aplicação em processamento de imagem. Especificamente, fez-se uso da estrutura




Fig. 3: Exemplos de resultados da detecção: **a)** em uma imagem com densidade nível 3, anomalia classificada com BI-RADS nível 4 ($IoU = 0.727$ e $score = 0.351$); **b)** em uma imagem com densidade nível 1, anomalia classificada com BI-RADS nível 4 ($IoU = 0.417$ e $score = 1.563$)

RetinaNet.

O modelo desenvolvido é capaz de detectar massas em mamografias, e os resultados obtidos se mostram comparáveis com outras publicações disponíveis na literatura.

A principal contribuição deste trabalho é a apresentação de um método de pré-processamento para subdivisão da imagem em múltiplas partes, e a etapa de pós-processamento para reagrupar as detecções feitas. Essas técnicas permitem utilizar eficientemente a rede RetinaNet com imagens de alta resolução, como mamografias, em dispositivos com poder computacional limitado.

Os resultados obtidos podem ser utilizados como base para o desenvolvimento de uma ferramenta de auxílio médico, permitindo um diagnóstico precoce e mais preciso do câncer de mama.

CONFLITO DE INTERESSE

Os autores declaram que não houve nenhum conflito de interesse no desenvolvimento deste artigo.

REFERÊNCIAS

1. <https://www.inca.gov.br/tipos-de-cancer/cancer-de-mama> 2018.
2. <https://www.femama.org.br/site/br/noticia/o-cancer-de-mama-em-numeros>.
3. Merino Bonilla JA, Torres Tabanera M, Ros Mendoza LH. Breast cancer in the 21st century: From early detection to new therapies. *Radio-logia*. 2017;59:368–379.
4. Russakovsky O, Deng J, Su H, et al. ImageNet large scale visual recognition challenge. *arXiv:1409.0575 [cs]*. 2015.

5. Krizhevsky A, Sutskever I, Hinton GE. ImageNet classification with deep convolutional neural networks. in *Advances in Neural Information Processing Systems 25* (Pereira F, Burges CJC, Bottou L, Weinberger KQ., eds.):1097–1105Curran Associates, Inc. 2012.
6. Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition. *arXiv:1409.1556 [cs]*. 2015.
7. He K, Zhang X, Ren S, Sun J. Deep residual learning for image recognition. *arXiv:1512.03385 [cs]*. 2015.
8. Jha D, Kim JI, Kwon GR. Diagnosis of Alzheimer's Disease using dual-tree complex wavelet transform, PCA, and feed-forward neural network. *J Healthc Eng.* 2017;2017:9060124.
9. Ding Y, Sohn JH, Kawczynski MG, et al. A deep learning model to predict a diagnosis of Alzheimer Disease by using 18F-FDG PET of the brain. *Radiology.* 2019;290:456–464.
10. Rajpurkar P, Irvin J, Zhu K, et al. CheXNet: Radiologist-Level pneumonia detection on chest X-rays with deep learning. *arXiv:1711.05225 [cs, stat]*. 2017.
11. Irvin J, Rajpurkar P, Ko M, et al. CheXpert: A large chest radiograph dataset with uncertainty labels and expert comparison. *arXiv:1901.07031 [cs, eess]*. 2019.
12. Elter M, Horsch A. CADx of mammographic masses and clustered microcalcifications: A review. *Med Phys.* 2009;36:2052–2068.
13. Jung H, Kim B, Lee I, et al. Detection of masses in mammograms using a one-stage object detector based on a deep convolutional neural network. *PLOS ONE.* 2018;13:e0203355.
14. Lee RS, Gimenez F, Hoogi A, Miyake KK, Gorovoy M, Rubin DL. A curated mammography data set for use in computer-aided detection and diagnosis research. *Scientific Data.* 2017;4:170177.
15. Fenton J, Taplin SH, Carney PA, et al. Influence of computer-aided detection on performance of screening mammography. *N. Engl. J. Med.* 2007;356:1399–1409.
16. Cole EB, Zhang Z, Marques HS, Hendrick RE, Yaffe MJ, Pisano ED. Impact of computer-aided detection systems on radiologist accuracy with digital mammography. *AJR Am J Roentgenol.* 2014;203:909–916.
17. Ren S, He K, Girshick R, Sun J. Faster R-CNN: Towards real-time object detection with region proposal networks. *arXiv:1506.01497 [cs]*. 2016.
18. Lin TY, Goyal P, Girshick R, He K, Dollár P. Focal loss for dense object detection. *arXiv:1708.02002 [cs]*. 2018.
19. Eltonsy NH, Tourassi GD, Elmaghraby AS. A concentric morphology model for the detection of masses in mammography. *IEEE Transactions on Medical Imaging.* 2007;26:880–889.
20. Sampat MP, Bovik AC, Whitman GJ, Markey MK. A model-based framework for the detection of spiculated masses on mammography. *Med Phys.* 2008;35:2110–2123.
21. Bellotti R, de Carlo F, Tangaro S, et al. A completely automated CAD system for mass detection in a large mammographic database. *Medical Physics.* 2006;33:3066–3075.
22. Shen L. End-to-end training for whole image breast cancer diagnosis using an all convolutional design. *Sci Rep.* 2019;9:12495.
23. Moreira IC, Amaral I, Domingues I, Cardoso A, Cardoso MJ, Cardoso JS. INbreast: Toward a full-field digital mammographic database. *Acad Radiol.* 2012;19:236–248.
24. Goodfellow I, Bengio Y, Courville A. *Deep Learning*. Adaptive Computation and Machine Learning SeriesCambridge, MA: MIT Press 2017.
25. Girshick R, Donahue J, Darrell T, Malik J. Rich feature hierarchies for accurate object detection and semantic segmentation. *arXiv:1311.2524 [cs]*. 2014.
26. Lin TY, Dollár P, Girshick R, He K, Hariharan B, Belongie S. Feature pyramid networks for object detection. in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*:936–944 2017.
27. Heath M, Bowyer K, Kopans D, et al. Current status of the digital database for screening mammography. in *Digital Mammography: Nijmegen, 1998* (Karssemeijer N, Thijssen M, Hendriks J, van Erning L., eds.)Computational Imaging and Vision:457–460Dordrecht: Springer Netherlands 1998.
28. Bodla N, Singh B, Chellappa R, Davis LS. Soft-NMS – Improving object detection with one line of code. *arXiv:1704.04503 [cs]*. 2017.
29. Beller M, Stotzka R, Müller TO, Gemmeke H. An example-based system to support the segmentation of stellate lesions. in *Bildverarbeitung Für Die Medizin 2005* (Meinzer HP, Handels H, Horsch A, Tolxdorff T., eds.)Informatik Aktuell(Berlin, Heidelberg):475–479Springer 2005.
30. Campanini R, Dongiovanni D, Iampieri E, et al. A novel featureless approach to mass detection in digital mammograms based on support vector machines. *Phys. Med. Biol.* 2004;49:961–975.
31. Dhungel N, Carneiro G, Bradley AP. Automated mass detection in mammograms using cascaded deep learning and random forests. in *2015 International Conference on Digital Image Computing: Techniques and Applications (DICTA)*:1–8 2015.

Author: Roberto Augusto Philippi Martins
Institute: Universidade Federal de Santa Catarina
Street:
City: Florianópolis
Country: Brasil
Email: roberto.apm@grad.ufsc.br